

Kestirimci Bakım Optimizasyonunda Çok Boyutlu Q-Learning ve Derin Q-Network (DQN) Yaklaşımlarının Karşılaştırmalı Analizi

Mustafa Baştürk

Bursa Teknik Üniversitesi, Lisansüstü Eğitim Enstitüsü

Özet

Endüstri 4.0 dönüşümüyle birlikte, üretim hatlarında meydana gelen plansız duruş sürelerinin (downtime) azaltılması ve endüstriyel varlıkların ömür döngüsü yönetiminin optimize edilmesi, operasyonel verimliliğin en kritik odak noktalarından biri haline gelmiştir. Bu çalışmada, kestirimci bakım (PdM) problemi ayrık zamanlı bir Markov Karar Süreci (MDP) olarak ele alınmıştır. Süreç sıcaklık farkları, tork dinamikleri ve kümülatif takım aşınması ilerlemesi gibi heterojen fiziksel değişkenleri içeren gerçek endüstriyel *ai4i2020* veri kümesi kullanılarak, iki temel Pekiştirmeli Öğrenme (RL) yaklaşımı tasarlanmış ve değerlendirilmiştir: Tabular tabanlı Çok Boyutlu Q-Learning ve Yapay Sinir Ağı tabanlı Derin Q-Network (DQN). Geliştirilen mimariler; yakınsama (convergence) hızları, doğrusal olmayan nesnel durumları modelleme yetenekleri ve katastrofik politika kaymalarına karşı direnç kriterleri doğrultusunda karşılaştırmalı analize tabi tutulmuştur.

Index Terms

Kestirimci Bakım, Pekiştirmeli Öğrenme, Çok Boyutlu Q-Learning, DQN, Endüstri 4.0.

I. GİRİŞ

Modern üretim tesislerinde geleneksel bakım stratejileri çoğunlukla reaktif (arıza sonrası müdahale) ya da periyodik (zaman tabanlı önleyici bakım) olarak ikiye ayrılmaktadır. Ancak reaktif stratejiler yüksek tamir maliyetlerine ve tedarik zinciri aksamlarına neden olurken, periyodik stratejiler ise henüz ekonomik ömrünü tamamlamamış parçaların gereksiz yere değiştirilmesine yol açarak maliyetleri artırır. Veri analitiği ve yapay zeka yaklaşımlarının gelişimiyle öne çıkan Kestirimci Bakım (Predictive Maintenance - PdM), endüstriyel sensör akışlarını gerçek zamanlı işleyerek arızaları henüz gerçekleşmeden önce tahmin etmeyi ve sadece ihtiyaç duyulduğunda bakım yapmayı amaçlar [1].

Son yıllarda, kestirimci bakım kararlarını dinamik birer stratejiye dönüştürmek amacıyla Pekiştirmeli Öğrenme (Reinforcement Learning) algoritmaları yoğun ilgi görmektedir [2]. Kestirimci bakım süreçleri, ajanın (öğrenen sistemin) makineyi çalıştırarak operasyonel ödülleri topladığı, ancak arıza veya gereksiz duruş durumlarında ağır cezalar aldığı bir optimizasyon problemi, yani bir Markov Karar Süreci (MDP) olarak modellenebilir. Bu raporda, söz konusu süreci çözmek amacıyla geliştirilen klasik çok boyutlu tabular Q-Learning algoritması [3] ile derin öğrenmenin genelleme gücünü arkasına alan DQN mimarisi [4], teorik ve pratik yönleriyle karşılaştırmalı olarak ele alınmıştır.

II. PROBLEM FORMULASYONU VE MDP MODELLEMESİ

Endüstriyel bir makinenin aşınma ve arıza döngüsü, $M = (S, A, P, R, \gamma)$ beşlisi ile tanımlanan sonlu bir Markov Karar Süreci (MDP) çerçevesinde formüle edilmiştir. Ortam, sürekli gerilime ve mekanik strese maruz kalan çok değişkenli bir sensör manifoldunu soyutlamaktadır.

A. Durum Uzayı (S)

Sistem durumunu ifade eden durum vektörü $s_t \in S$, her t zaman adımında fiziksel sensörlerden okunan heterojen değerleri yakalar:

$$s_t = \begin{bmatrix} \Delta T_t \\ \tau_t \\ w_t \end{bmatrix} \quad (1)$$

Burada kullanılan parametreler UCI Machine Learning Repository üzerinde sunulan endüstriyel *ai4i2020* veri setine dayanmaktadır [5]:

- ΔT_t : Proses sıcaklığı ile ortam hava sıcaklığı arasındaki net termal fark ($T_{\text{proses}} - T_{\text{hava}}$). Sıcaklık farkının artması, sistemdeki sürtünme ve termal gerilimin doğrudan bir göstergesidir.
- τ_t : Motor veya mil üzerindeki anlık operasyonel tork değeri (Nm).
- w_t : Kesici takımın veya mekanik bileşenin operasyon başladığından beri maruz kaldığı kümülatif takım aşınma süresi (*dakika*).

B. Aksiyon Uzayı (A)

Ajanın seçebileceği aksiyon uzayı kesin olarak ayrık ve ikilidir (binary). Bu seçimler endüstriyel sistem üzerindeki operasyonel stratejiyi dikte eder:

- a_0 = Operasyona Devam Et: Üretim döngüsünü kesintisiz devam ettirir. Sistemi bir sonraki zaman adımında yeni stokastik aşınma ve arıza risklerine maruz bırakır.
- a_1 = Bakım Tetikle (Sıfırla): Üretim hattını durdurur. Aşınmış bileşenleri restore ederek veya değiştirerek sistem durumunu nominal bir başlangıç çizgisine geri döndürür.

Şekil 1: Kestirimci bakım modelinde ajan kararlarına göre motor fiziksel durumlarının ve sensör barlarının dinamik simülasyon çıktısı.

III. ALGORİTMİK MİMARİLER VE TEORİK ALTYAPI

A. Çok Boyutlu Tabular Q -Learning

Sürekli bir veri akışı üzerinde tabular öğrenmeyi uygulayabilmek için sensör akışları, tekdüze bir adım haritalama fonksiyonu olan $f : \mathbb{R}^3 \rightarrow \mathbb{N}^3$ aracılığıyla ayrıklaştırılmış (discretization) bir durum tensörüne projekte edilir. Bu süreç, karmaşık sensör değerlerini mühendislik sınır koşullarına göre 3 temel sıralı risk bölmesine ayırır (0: Nominal/Düşük, 1: Orta, 2: Kritik/Yüksek).

Optimal aksiyon-değer fonksiyonu $Q^*(s, a)$, zamansal fark (Temporal Difference - TD) mantığına dayanan Bellman optimalite denklemi aracılığıyla her döngüde güncellenir [3]:

$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha \left[r_t + \gamma \max_a Q(s_{t+1}, a) - Q(s_t, a_t) \right] \quad (2)$$

Burada $\alpha \in (0, 1]$ öğrenme oranını (learning rate) temsil ederken; $\gamma \in [0, 1)$ ise gelecek ödüllerin indirgeme oranıdır (discount factor).

B. Derin Q -Networks (DQN)


Ayrıklaştırma işleminden kaçınarak sürekli durum uzayını doğrudan işleyebilmek adına, Q -tablosunu saklamak yerine ağırlıkları θ ile ifade edilen parametrik bir sinirsel tahminci [$Q(s, a; \theta) \approx Q^*(s, a)$] devreye alınmıştır [4]. Endüstriyel zaman serisi verilerinin doğasında bulunan ardışık veri korelasyonlarını kırmak ve durağan olmayan hedef problemini engellemek amacıyla sisteme Derin Deneyim Tekrarı Hafızası (Replay Buffer - $\mathcal{D}$) ve birbirinden ayrılmış Hedef Ağlar (Target Network - θ^-) entegre edilmiştir.

DQN mimarisi, ortalama karesel Bellman hatası (MSBE) kayıp fonksiyonunu her adımda minimize ederek optimize edilir:

$$L_i(\theta_i) = \mathbb{E}_{(s, a, r, s') \sim \mathcal{D}} \left[\left(r + \gamma \max_{a'} Q(s', a'; \theta_i^-) - Q(s, a; \theta_i) \right)^2 \right] \quad (3)$$

IV. AMPİRİK DEĞERLENDİRME VE YAKINSAMA DİNAMİKLERİ

Çalışmada kullanılan ödül ve ceza fonksiyonu tasarımı, endüstriyel işletme mantığına dayalı sıkı bir kısıt optimizasyonu problemini zorunlu kılar. Tasarlanan model; operasyonel üretim kazançlarını ($r_{\text{adım}} = +10$), bakım duruş maliyetlerine ($r_{\text{bakım}} = -50$) ve katastrofik makine arıza olaylarına ($r_{\text{arıza}} = -2000$) karşı dengeler.



Şekil 2: Çok Boyutlu Q-Learning modelinin 15.000 episode boyunca kümülatif ödül yakınsama (convergence) ve başarı eğrisi eğilimi.

A. Karşılaştırmalı Analiz Matrisi

Algoritmaların ampirik testler sonucunda ortaya koyduğu karakteristik farklar Tablo I üzerinde detaylandırılmıştır:

Tablo I: Tabular Çok Boyutlu Q-Learning ve Derin Q-Network (DQN) Parametrik Karşılaştırma Matrisi

Metrik / Özellik	Çok Boyutlu Tabular Q-Learning	Derin Q-Network (DQN) Haritalaması
Durum Çözünürlüğü	Ayrıklaştırılmış Tensörler ($3 \times 3 \times 3$ Uzay)	Sürekli Normalize Edilmiş Alt Uzay $[0, 1]^3$
Politika Kararlılığı	Mutlak (Matematiksel Yakınsama Garantili)	Düşük (Politika bozulmasına eğilimli)
Hesaplama Maliyeti	İhmal Edilebilir ($\mathcal{O}(1)$ Doğrudan İndisleme)	Yüksek ($\mathcal{O}(N)$ Geri Yayılım Yükü)
Katastrofik Körlük	Bağışık (Hücre bazlı ceza takibi açıktır)	Yüksek (Kısa vadeli optimizasyona duyarlı)
Ölçeklenebilirlik	Düşük (Boyutluluğun Laneti mevcuttur)	Yüksek (Yüksek boyutlu uzayları haritalar)

B. Yakınsama Performansı ve Politika Miyopluğu Problemi

Eğitim eğrilerinin analizi, derin pekiştirmeli öğrenme modellerinin endüstriyel ortamlardaki hassasiyetini açıkça ortaya koymaktadır [4]. DQN modelleri doğrusal olmayan karmaşık ilişkileri öğrenmede başarılı olsa da, anlık durum sıfırlamaları (bakım aksiyonu sonrası sistemin aniden gıcır gıcır hale gelmesi) sınır ağlarında kararsızlıklara yol açar. Ödül ödeneği yüksek olduğunda ajan "açgözlü" davranarak kritik sınırlardaki arıza risklerini tamamen görmezden gelebilir. Ödüller azaldığında ise "korkak" bir mod sergileyerek, sistem henüz tamamen güvenli ve ideal durumdayken bile gelecekteki arıza cezasından kaçmak amacıyla sürekli bakım eylemini tetikler.

Buna karşın, Çok Boyutlu Q-Learning modelinde durumlar net matris duvarlarıyla ayrıldığı için, keşif (exploration) aşaması tamamlandıktan sonra hareketli ortalama çizgisi dipten başlayarak kararlı bir şekilde yukarı tırmanır ve zirvede doyum noktasına (convergence) ulaşarak sabitlenir (Bkz. Şekil 2).

V. DOĞRULAMA MATRİSİ VE POLİTİKA ÇIKTILARI

Eğitilen modelin endüstriyel operasyon mantığına uygunluğu ve doğruluğu, sistem döngüsündeki iki mutlak uç senaryo (edge case) üzerinde test edilerek doğrulanmıştır. Yapılan nihai doğrulama testleri sonucunda elde edilen kararlı terminal çıktı tablosu şu şekildedir:

```
=====
----- ÖĞRENİLEN OPTİMAL STRATEJİ SONUÇLARI (NİHAİ TEST) -----
=====
Girdi Sensör Durumu (Sıcaklık, Tork, Aşınma) | Karar
-----
İdeal Senaryo (Düşük Risk Modu - [0, 0, 0]) | DEVAM ET
Kritik Senaryo (Yüksek Risk Modu - [2, 2, 2]) | BAKIM YAP
```

=====

Bu tablo, ajanın her iki senaryoda da rasyonel bir mühendislik kararı verdiğini kanıtlamaktadır: Sistem yeni ve temizken üretimi maksimize etmek için çalışmayı sürdürürken, sensörler alarm verdiğinde katastrofik arıza maliyetinden kaçınmak için anında güvenli bakım moduna geçmektedir.

VI. SONUÇ

DQN modelleri sürekli durum alım kapasitesi sunar, ancak bakım eylemlerinin (a_1) neden olduğu anlık durum sıfırlamaları gibi ani ortam geçişleriyle karşılaştıklarında derin politika dalgalanmalarına karşı savunmasız kalırlar. Bu durum, modelin ya aşırı temkinli (korkak) ya da aşırı agresif (açgözlü) kararlar üretmesine neden olur.

Buna karşılık, **Çok Boyutlu Tabular Q-Learning**, izole edilmiş durum-aksiyon uzaylarını doğrudan yönetir. Bu yapısal netlik, sinirsel genelleme hatalarını ortadan kaldırarak ajanın, üretim çıktısını maksimize etme ile kestirimci duruş yönetimi arasında optimal bir denge kurmasını sağlar. Sınırlı endüstriyel otomasyon döngüleri için çok boyutlu tabular algoritma, kritik sistemlerde konuşlandırılmak üzere en güvenilir çerçeveyi sunmaktadır.

KAYNAKLAR

- [1] R. K. Mobley, *An introduction to predictive maintenance*. Elsevier, 2002.
- [2] R. S. Sutton and A. G. Barto, *Reinforcement learning: An introduction*. MIT press, 2018.
- [3] C. J. Watkins and P. Dayan, “Q-learning,” *Machine learning*, vol. 8, no. 3, pp. 279–292, 1992.
- [4] V. Mnih, K. Kavukcuoglu, D. Silver, *et al.*, “Human-level control through deep reinforcement learning,” *Nature*, vol. 518, no. 7540, pp. 529–533, 2015.
- [5] S. Matzka, “Explainable artificial intelligence for predictive maintenance in industry 4.0,” in *2020 International Conference on Data Mining Workshops (ICDMW)*. IEEE, 2020, pp. 26–33.